

## 混淆矩阵

混淆矩阵也称误差矩阵，是机器学习和统计分类中用于查看分类结果的表格，尤其常用于监督学习。它把实际类别与预测类别放在一起，帮助读者看出模型分对了多少样本，又把哪些类别混淆了。在无监督学习中，相应的表格一般称为匹配矩阵。

从结构上看，混淆矩阵是一种二维列联表：两个维度分别是实际类别和预测类别，使用相同的类别集合。本文统一用行表示实际类别、列表示预测类别。

### 猫狗分类示例

假设一个已经训练好的系统需要区分猫和狗。测试样本共有 13 个动物，其中有 8 只猫、5 只狗。系统的预测结果如下：

| 实际类别 | 预测为猫     | 预测为狗     |
|------|----------|----------|
| 猫    | <b>5</b> | 3        |
| 狗    | 2        | <b>3</b> |

8 只猫中，5 只被正确识别为猫，3 只被误判为狗；5 只狗中，2 只被误判为猫，3 只被正确识别为狗。

当行和列按相同的类别顺序排列时，正确预测位于主对角线上，也就是表中加粗的两个数。对角线以外的数则表示误判，因此可以直接看出错误发生在哪两个类别之间。

### 二分类中的四种结果

对于只有两个类别的任务，混淆表是一个两行两列的表，用来记录真阳性、假阴性、假阳性和真阴性的数量。解释这些术语前，需要先明确哪个类别是阳性。这里以猫为阳性、狗为阴性：

| 实际类别  | 预测为猫（阳性）  | 预测为狗（阴性）  |
|-------|-----------|-----------|
| 猫（阳性） | 真阳性（TP）：5 | 假阴性（FN）：3 |
| 狗（阴性） | 假阳性（FP）：2 | 真阴性（TN）：3 |

真阳性和真阴性都是正确预测。假阳性是把狗误判为猫，假阴性则是把猫误判为狗。这四种计数既能用于计算总体准确度，也能帮助分析模型具体犯了什么错误。

### 类别不平衡时，如何理解指标

准确度表示预测正确的样本占全部样本的比例。但当不同类别的样本数量相差很大时，单看准确度可能产生误导。

例如，数据中有 95 只猫、5 只狗，而分类器把所有动物都预测为猫。此时，95 只猫全部分对，5 只狗全部分错，总体准确度仍达到 95%。以猫为阳性类别，四种计数为：

| 实际类别 | 预测为猫 | 预测为狗 |
|------|------|------|
| 猫    | 95   | 0    |
| 狗    | 5    | 0    |

猫的识别率为 100%，也就是敏感性；狗的识别率却为 0%。在这一阳性类别约定下，狗的识别

率也就是特异性。

F1 得分 (F1 score) 同样可能掩盖这个问题。以猫为阳性类别计算, F1 得分为:

$$F_1 = \frac{2TP}{2TP + FP + FN} = \frac{2 \times 95}{2 \times 95 + 5 + 0} = \frac{190}{195} \approx 97.4\%.$$

未舍入的结果略高于 97.4%, 甚至高于总体准确度, 却仍对应一个完全识别不出狗的分类器。因此, 这里的高 F1 得分不能说明模型对两个类别都有良好的识别能力; 该数值特指以猫为阳性类别的计算结果。

约登指数将敏感性和特异性结合起来, 可以避免本例中多数类占比过高造成的高分假象。其定义为:

$$J = \text{敏感性} + \text{特异性} - 1.$$

对这个总是猜猫的分类器, 有:

$$J = \frac{95}{95 + 0} + \frac{0}{0 + 5} - 1 = 0.$$

这里的  $J = 0$  表示分类器没有提供有效的类别区分信息: 它虽然因猫的数量多而取得较高准确度, 却始终给出同一个答案。从区分两类的角度看, 这种判别没有作用。约登指数是衡量区分能力的指标, 不应把它直接理解为“作出有信息量决定的概率”。

混淆矩阵还可以用于计算其他指标。选择指标时, 需要结合类别分布和分析目的, 并检查各类样本的识别情况。

## 参考资料

- 国家教育研究院术语资源: “confusion matrix — 误差矩阵; 混淆矩阵”。
- Wikipedia: “Youden’s J statistic”。